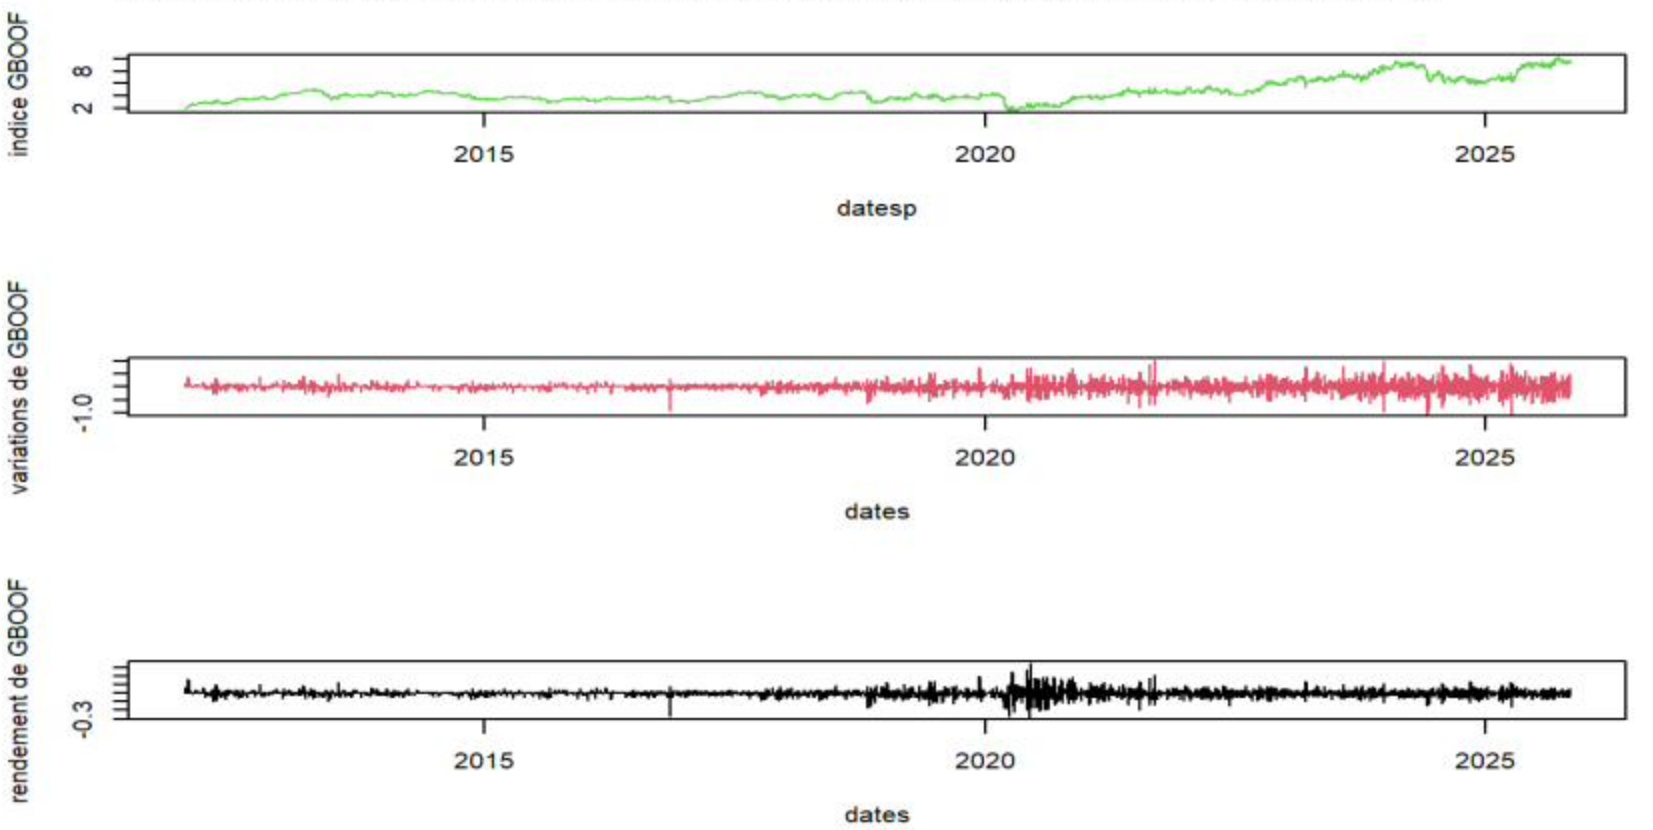
Projet VaR fiche 2
Grupo Financiero Banorte
Enzo Lamaison

Grupo Financiero Banorte (GBOOF), S.A.B. de C.V. est une institution financière majeure au Mexique, opérant principalement dans les services bancaires et financiers. Elle offre une large gamme de produits et services, incluant la banque commerciale, la banque de détail, les services de courtage, le leasing, le factoring, les assurances ainsi que la gestion des retraites. Banorte est reconnue comme l'une des plus grandes banques mexicaines en termes de taille et de dépôts. Voici quelque chiffres clé pour comprendre le poids de la banque : un chiffre d'affaires annuel : environ 429,82 milliards de pesos mexicains, pour un résultat net annuel : environ 57,87 milliards de pesos mexicains ainsi qu'une capitalisation boursière : environ 502,18 milliards de pesos mexicains. Cette institution comporte environ plus 32 300 employés.

Pour réaliser ce projet l'action GBOOF les données ont été récupéré sur "2012-01-02" au 2025-11-10"



L'indice GBOOF présente une tendance clairement croissante sur l'ensemble de la période 2012–2025, avec une progression particulièrement marquée à partir de 2020. En revanche, les variations dp_t et le rendement logarithmique r_t fluctuent autour de 0. Les amplitudes des fluctuations ne sont cependant pas constantes : on distingue des épisodes de forte volatilité (paquets de volatilité) autour de 2020, où les rendements présentent des mouvements extrêmes sur de courtes périodes.

Propriété 8 : Stationnarité

Dickey-Fuller
On cherche à tester l'hypothèse suivante :
• *H0 : ρ−1=0 β1 =0*
• *H1 : |ρ| <1 et β1 ≠0*
La statistique associée à $\rho - 1$ est comparée aux valeurs critiques de Dickey-Fuller. Si la statistique est inférieure à la valeur critique au seuil de 5 %, on rejette l'hypothèse de racine unitaire (H_0), et on conclut que la série des rendements

logarithmiques est stationnaire. Dans le cas contraire, on ne rejette pas H_0 et la série est considérée comme non stationnaire

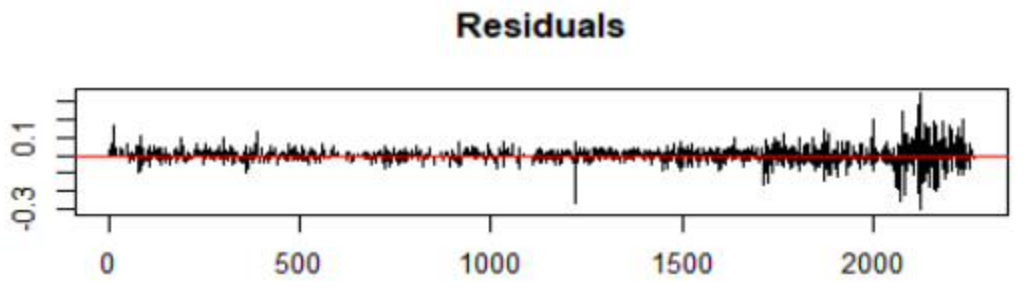
Etant donné que β1 n'est pas significatif (voir annexe), on l'enlève du modèle et on teste la spécification drift. β0 n'étant pas significatif (voir annexe), on garde la spécification none

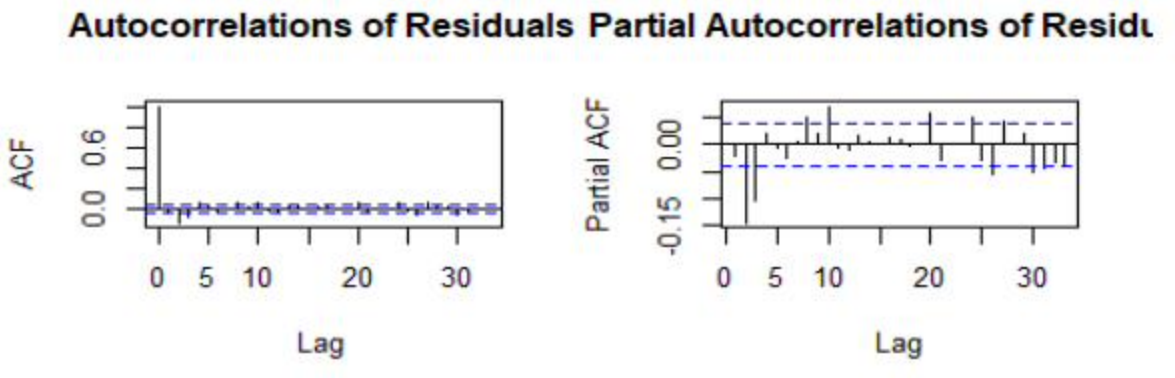
```
summary(ur.df(rte, type="none", lags=0))
```

```
Call:
lm(formula = z.diff ~ z.lag.1 - 1)
Residuals:
     Min       1Q   Median       3Q      Max
-0.30787 -0.00587  0.00000  0.00733  0.34918
Coefficients:
        Estimate Std. Error t value Pr(>|t|)
z.lag.1 -1.15601    0.02077  -55.66   <2e-16 ***
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.03651 on 2262 degrees of freedom
Multiple R-squared:  0.578,    Adjusted R-squared:  0.5778
F-statistic:  3098 on 1 and 2262 DF,  p-value: < 2.2e-16
Value of test-statistic is: -55.6597
Critical values for test statistics:
      1pct  5pct 10pct
tau1 -2.58 -1.95 -1.62
```

t calculé =−55.6597<-1.95 donc on rejette H0 donc le PGD n'est pas DS. On rejette donc l'hypothèse de racine unitaire : la série des rendements logarithmiques de Banorte est stationnaire. Cette conclusion n'est valide que si les aléas de la régression de Dickey et Fuller ne sont pas auto-corrélés. Vérifions maintenant :

```
plot(ur.df(rte, type = "none", lags = 0))
```





On constate la présence d'autocorrélations dans les résidus, on augmente alors le nombre maximum de lag du modèle Dickey-Fuller augmenté.

Le test de Dickey-Fuller augmenté avec le critère MAIC nous donne max.lag = 0 (voir annexe). On refait alors le test avec lag = schwert.

```
summary(ur.df(rte, type= "none", lags=Schwert))
```

```
Test regression none
Call:
```

```
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
Residuals:
      Min        1Q    Median        3Q       Max
-0.284079 -0.008399  0.000066  0.009508  0.273387
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
z.lag.1      -1.204484   0.143034  -8.421   <2e-16 ***
z.diff.lag1   0.011041   0.140646   0.079   0.9374
z.diff.lag2  -0.140813   0.138369  -1.018   0.3089
z.diff.lag3  -0.273987   0.136147  -2.012   0.0443 *
z.diff.lag4  -0.279253   0.133799  -2.087   0.0370 *
z.diff.lag5  -0.280901   0.131431  -2.137   0.0327 *
z.diff.lag6  -0.299350   0.128997  -2.321   0.0204 *
z.diff.lag7  -0.293610   0.126567  -2.320   0.0204 *
z.diff.lag8  -0.231384   0.123833  -1.869   0.0618 .
z.diff.lag9  -0.203387   0.120975  -1.681   0.0929 .
z.diff.lag10 -0.132633   0.117976  -1.124   0.2610
z.diff.lag11 -0.123068   0.114750  -1.072   0.2836
z.diff.lag12 -0.134703   0.111386  -1.209   0.2267
z.diff.lag13 -0.114150   0.107892  -1.058   0.2902
z.diff.lag14 -0.104088   0.104238  -0.999   0.3181
z.diff.lag15 -0.098740   0.100340  -0.984   0.3252
z.diff.lag16 -0.081783   0.096380  -0.849   0.3962
z.diff.lag17 -0.062014   0.092276  -0.672   0.5016
z.diff.lag18 -0.052651   0.087503  -0.602   0.5474
z.diff.lag19 -0.052002   0.082243  -0.632   0.5273
z.diff.lag20  0.002961   0.076073   0.039   0.9690
z.diff.lag21 -0.008539   0.069246  -0.123   0.9019
z.diff.lag22 -0.002774   0.061855  -0.045   0.9642
z.diff.lag23 -0.007516   0.053440  -0.141   0.8882
z.diff.lag24  0.037688   0.043481   0.867   0.3862
z.diff.lag25  0.021696   0.032979   0.658   0.5107
z.diff.lag26 -0.036419   0.021261  -1.713   0.0869 .
Signif. codes:
0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
Residual standard error: 0.0357 on 2210 degrees of freedom
Multiple R-squared:  0.602,    Adjusted R-squared:  0.5972
F-statistic: 123.8 on 27 and 2210 DF,  p-value: < 2.2e-16
Value of test-statistic is: -8.421
Critical values for test statistics:
      1pct  5pct 10pct
tau1 -2.58 -1.95 -1.62
```

Schwert (26) correspond au nombre de lag qui rend le dernier lag significatif (| t |> 1.6). En utilisant le test Augmented Dickey-Fuller , on obtient une statistique de test de -8.42, nettement plus négative que la valeur critique de -1.95 au seuil de 5 %. On rejette donc avec certitude l'hypothèse de non-stationnarité : la série des rendements logarithmiques de Banorte est stationnaire sur la période considérée.

Zivot-Andrews

On cherche à tester l'hypothèse suivante :

- H0 : ρ=1(DS sans changement structurel)
- H1 : |ρ| < 1 (TS avec un unique changement structurel)

La règle de décision est de rejeter H0 si la statistique calculée est inférieure à la valeur critique au seuil de risque α de la queue gauche de la distribution de la statistique sous H0 pour λ fixe

```
summary(ur.za (rte,  model="both", lag=Schwert))
```

```
Residuals:
```

```
      Min        1Q    Median        3Q       Max
-0.275299 -0.009204 -0.000284  0.009071  0.280882
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  9.932e-04  1.623e-03   0.612 0.540689
y.l1        -4.667e-01  1.563e-01  -2.985 0.002867 **
trend       -5.714e-07  1.363e-06  -0.419 0.675111
y.dl1        2.655e-01  1.534e-01   1.731 0.083637 .
y.dl2        1.049e-01  1.505e-01   0.697 0.485914
y.dl3       -3.806e-02  1.475e-01  -0.258 0.796400
y.dl4       -5.417e-02  1.443e-01  -0.375 0.707415
y.dl5       -6.657e-02  1.411e-01  -0.472 0.637234
y.dl6       -9.540e-02  1.380e-01  -0.692 0.489304
y.dl7       -1.001e-01  1.348e-01  -0.743 0.457745
y.dl8       -4.856e-02  1.313e-01  -0.370 0.711609
y.dl9       -3.151e-02  1.278e-01  -0.247 0.805209
y.dl10       2.858e-02  1.241e-01   0.230 0.817871
y.dl11       2.791e-02  1.203e-01   0.232 0.816509
y.dl12       5.895e-03  1.163e-01   0.051 0.959578
y.dl13       1.610e-02  1.122e-01   0.143 0.885948
y.dl14       1.572e-02  1.080e-01   0.146 0.884322
y.dl15       1.087e-02  1.036e-01   0.105 0.916449
y.dl16       1.813e-02  9.920e-02   0.183 0.855011
y.dl17       2.814e-02  9.465e-02   0.297 0.766265
y.dl18       2.751e-02  8.946e-02   0.308 0.758465
y.dl19       1.806e-02  8.381e-02   0.215 0.829400
y.dl20       6.271e-02  7.728e-02   0.812 0.417130
y.dl21       4.144e-02  7.014e-02   0.591 0.554683
y.dl22       3.801e-02  6.249e-02   0.608 0.543125
y.dl23       2.381e-02  5.385e-02   0.442 0.658379
y.dl24       5.963e-02  4.369e-02   1.365 0.172504
y.dl25       3.511e-02  3.305e-02   1.062 0.288239
y.dl26      -3.014e-02  2.126e-02  -1.418 0.156328
du          -1.922e-02  5.417e-03  -3.548 0.000396 ***
dt           1.692e-04  4.162e-05   4.064 4.98e-05 ***
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.03559 on 2206 degrees of freedom
  (27 observations effacées parce que manquantes)
Multiple R-squared:  0.08548,         Adjusted R-squared:  0.07304
F-statistic: 6.873 on 30 and 2206 DF,  p-value: < 2.2e-16
Teststatistic: -9.381
Critical values: 0.01= -5.57 0.05= -5.08 0.1= -4.82
Potential break point at position: 2045
```

Le test Zivot-Andrews pour la stationnarité des rendements logarithmiques de Banorte, avec optimisation du lag par Schwert, révèle une statistique de test de –9.381, nettement inférieure à la valeur critique de –5.08 au seuil de 5 %. Les coefficients de rupture sont tous deux significatifs. On rejette donc H0 et conclut que la série est stationnaire, même en tenant compte d'une rupture structurelle significative autour de la position 2045."

Test de Lee et Strazicich

Ils supposent que X0 la condition initiale est fixe et $\epsilon \sim N(0,\sigma 2)$ et notent y1, la première valeur de y. L'hypothèse nulle de RU est $\beta = 1$ versus Ha : $\beta < 1$

```
myBreaks <- 1
myModel <- "break"
myLags <- 5
```

```
myLS_test <- ur.ls(y=rte , model = myModel, breaks = myBreaks, lags = myLags, method = "GTOS",pn = 0.1, print.results = "print" )
```

```
-35.55321
[1] "First possible structural break at position: 2026"
[1] "The location of the first break - lambda_1: 0.9 , with the number of total obse
rvations: 2264"
Critical values - Break model:
     lambda    1%    5%   10%
[1,]    0.1 -5.11 -4.50 -4.21
[2,]    0.2 -5.07 -4.47 -4.20
[3,]    0.3 -5.15 -4.45 -4.18
[4,]    0.4 -5.05 -4.50 -4.18
[5,]    0.5 -5.11 -4.51 -4.17
[1] "Number of lags determined by general-to-specific lag selection: 2"
Runtime:
Time difference of 0.2376382 mins
```

Le test Lee-Strazicich donne une statistique de test de –35.55, nettement plus faible que la valeur critique de –4.51 au seuil de 5 %. On rejette donc de façon très robuste l'hypothèse de racine unitaire, ce qui valide la stationnarité des rendements, même lorsque l'on considère l'existence d'une rupture structurelle à la position 2026, c'est-à-dire vers la fin de la période d'analyse.

Propriété 1 : Asymétrie perte/gain

On veut tester la présence d'une asymétrie dans rte. On test

• H0 : E [$(\frac{X-E(X)}{\sigma X})$^3]= 0

• H1 : E [$(\frac{X-E(X)}{\sigma X})$^3] ≠ 0

Sous H0, la statistique de tesTapez une équation ici.t suit une loi normale centrée réduite

```
agostino.test(rte)
```

```
D'Agostino skewness test
data:  rte
skew = 0.13013, z = 2.52562, p-value = 0.01155
alternative hypothesis: data have a skewness
```

Etant donné que p = 0.01155, on rejette l'hypothèse nulle d'absence d'asymétrie et on conclut à la présence d'une asymétrie positive car skew = 0.13013. On constate alors davantage de rendements négatifs que positifs, mais ces derniers représentent des montants plus élevés

Propriété 2 : Queues de distribution épaisses

On veut tester la présence d'une asymétrie dans rte. On test :

• H0 : E [$(\frac{X-E(X)}{\sigma X})$^4]=3

• H1 : E [$(\frac{X-E(X)}{\sigma X})$^4] ≠ 3

Si la kurtosis > 3 la distribution est leptokurtique, si elle est <3, la distribution est platikurtique.

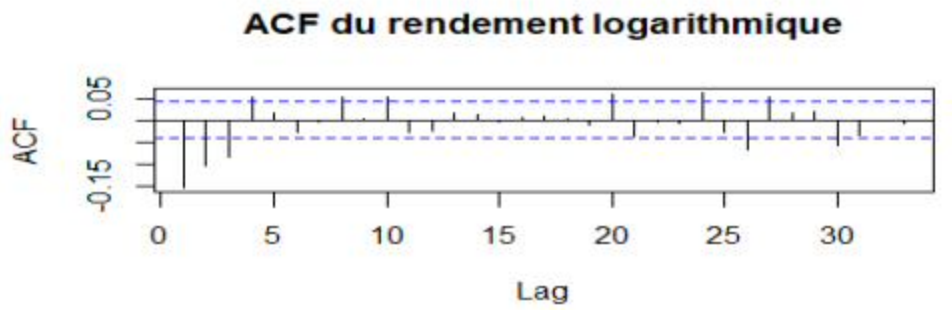
```
anscombe.test(rte)
```

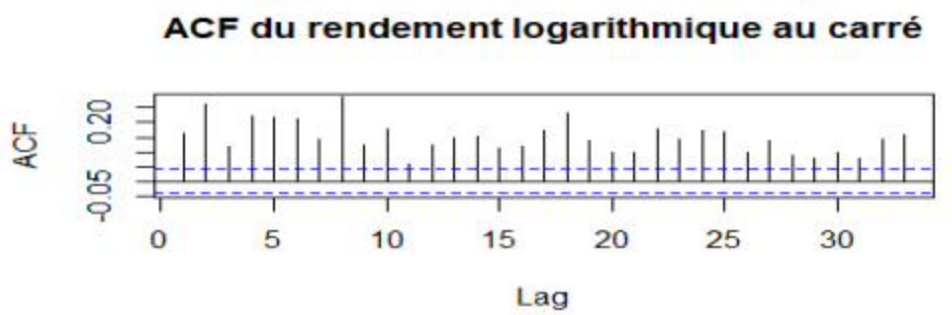
```
Anscombe-Glynn kurtosis test
data:  rte
kurt = 19.695, z = 22.914, p-value < 2.2e-16
alternative hypothesis: kurtosis is not equal to 3
```

Etant donné que p = 2.2e − 16, on rejette l'hypothèse nulle d'un kurtosis égal à 3 et on conclut à une distribution leptokurtique des rendements logarithmiques car kurt ≈ 19.695(> 3).

Propriété 3 : Autocorrélation

```
op<-par(mfrow=c(2,1))
 Acf(rte,main='ACF du rendement logarithmique')
 Acf(rte^2,main='ACF du rendement logarithmique au carré')
 par(op)
```





L'ACF sur les rendements logarithmiques nous indique la présence d'autocorrélation à l'ordre 1, 2, 3, 4, 8, 10, 20, 24, 26, 27 et 30 puisque les statistiques calculées à ces ordres dépassent les bornes de l'intervalle de confiance.
L'ACF sur les rendements logarithmiques au carré nous indique la présence d'autocorrélation à tous les ordres jusqu'à 33 au moins.

La statistique de Ljung-Box :

- H0 : $\rho(1) = \rho(2) = \cdots = \rho(K) = 0$
- H1 : au moins 1 $\rho(k) \neq 0$

```
pvaluesrt =rep(0,20)
> pvaluesrt2 =rep(0,20)
> for (i in 1:25 ) {
+ pvaluesrt[i] = Box.test(rte,lag=i,type="Ljung-Box")$p.value
+ pvaluesrt2[i] = Box.test(rte^2,lag=i,type="Ljung-Box")$p.value }
```

```
pvaluesrte
 [1] 8.169363e-02 1.295543e-01 7.320204e-03 1.676954e-02
 [5] 9.821374e-05 2.382795e-04 5.326795e-04 1.108100e-03
 [9] 1.463696e-03 1.161778e-03 1.990844e-03 3.430689e-03
[13] 5.519386e-03 3.755974e-03 4.009583e-03 5.874545e-03
[17] 5.810783e-03 3.786197e-03 3.709066e-03 3.597290e-03
[21] 5.266391e-03 2.942483e-03 2.949451e-03 1.696467e-03
[25] 1.546821e-05
```

La série des rendements rte montre une absence d'autocorrélation significative aux tout premiers retards car la pvalue du test de LB est < à 5%, mais une autocorrélation faible devient détectable à partir du lag 3. On utilisera le modèle AR MA pour modéliser.

```
>   pvaluesrte2
 [1] 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
```

Elles sont toutes nulles donc on conclut à la présence d'autocorrélation dans les rendements au carré. Ce résultat confirme la présence de clusters de volatilité et justifie pleinement l'utilisation de modèles ARCH pour modéliser la dynamique de la variance des rendements

```
eacf(rte)
```

```
AR/MA
  0 1 2 3 4 5 6 7 8 9 10 11 12 13
0 x x x x o o o x o x o  o  o  o
1 x o x x o o o x o x o  o  o  o
2 x x x o o o o o o x o  o  o  o
3 o o x x o o o o o x o  o  o  o
4 x o x o o o o x o x o  o  o  o
5 x x o o x x o x o x o  o  o  o
6 x x o o x x o x x x x  o  x  o
7 x x o x x x x x o x x  o  o  o
```

On trouve que p = 0 et q = 10. On fait donc l'estimation d' un MA(10)

```
regrte<-Arima(rte, order=c(0,0,10),fixed=c(NA,NA,NA,NA,0,0,0,NA,0,0,0))
coeftest(regrte)
Estimate Std. Error z value  Pr(>|z|)
ma1 -0.196470   0.020974 -9.3675 < 2.2e-16 ***
ma2 -0.116709   0.021269 -5.4874  4.08e-08 ***
ma3 -0.075124   0.021991 -3.4161 0.0006353 ***
ma4  0.060418   0.021013  2.8753 0.0040370 **
ma8  0.066702   0.019902  3.3516 0.0008035 ***
```

Les différents modèles ARMA(0,10) estimés montrent que seuls quelques coefficients de moyenne mobile (ma1, ma2, ma3, ma4, ma8) (voir annexe pour détail) sont réellement significatifs car ce sont les seules avec une p value < 5%. La simplification du modèle en supprimant les coefficients non significatifs permet d'obtenir un modèle parcimonieux et adapté, qui capture efficacement les dynamiques temporelles des rendements. Ce choix est validé à la fois par la significativité des paramètres et la logique de sélection présentée dans le projet.

On test la nullité de la moyenne des résidus :

Ha : $E(\epsilon) \neq 0$

```
residurte<-regrte$res
t.test(residurte)
data:  residurte
t = 0.54165, df = 2263, p-value = 0.5881
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.001068249  0.001883566
sample estimates:
   mean of x
0.0004076585
```

La p.value= 0.5881 est >0.05 donc on ne rejette pas H0 donc l'espérance des aléas est nulle et on passe au test d'absence d'autocorrélation.

```
residuvrte=(residurte-mean(residurte))/sd(residurte)
K<-20
tmp<-rep(0,K)
for(i in 1:K){
 tmp[i]<-Box.test(residuvrte,lag=i,type="Ljung-Box")$p.value}
 [1] 0.9702243 0.9992389 0.9999215 0.9999217 0.9809138
 [6] 0.9556101 0.9709595 0.9860115 0.9938974 0.7047813
[11] 0.6900289 0.6805167 0.7096552 0.7500974 0.8063955
[16] 0.8461898 0.8378942 0.8722924 0.9054636 0.5470637
```

Aucune p-value n'est inférieure à 5% jusqu'à l'ordre 20, on en conclut à l'absence d'autocorrélation dans les résidus du modèle et donc à la bonne spécification de ce dernier.

Propriété 4 : Clusters de volatilité

On cherche à tester la présence d'hétéroscédasticité conditionnelle et on fait l'hypothèses :

• H0 : α0 =α1 =⋯=αm =0

• H1 : au moins 1 αk/=0, i.e présence hétéroscédasticité conditionnell

```
ArchTest(as.numeric(rte),lag=1)
```

```
ARCH LM-test; Null hypothesis: no ARCH effects
data:  as.numeric(rte)
Chi-squared = 61.553, df = 1, p-value = 4.309e-15
```

On a une p-value de 4.3×10^{-15} ceci permet de rejeter sans ambiguïté l'hypothèse d'absence d'hétéroscédasticité conditionnelle : la série présente un effet ARCH significatif.

Propriété 5 Queues épaisses conditionnelles

Si la statistique de test indique une kurtosis significativement différente de 3 (valeur théorique de la normale) et la p-value est inférieure à 5 %, on rejette H_0 : les résidus sont leptokurtiques, la distribution n'est pas normale.

Si la p-value est supérieure à 5 %, on ne rejette pas H_0 : les résidus sont compatibles avec la normalité.

```
volatrte<-garch(residuvrte,order=c(1,1))
summary(volatrtt)
```

```
Coefficient(s):
    Estimate  Std. Error  t value Pr(>|t|)
a0 0.0052958   0.0005563    9.519   <2e-16 ***
a1 0.0486935   0.0021223   22.944   <2e-16 ***
b1 0.9463575   0.0022230  425.703   <2e-16 ***
Box-Ljung test
data:  Squared.Residuals
X-squared = 0.11784, df = 1, p-value = 0.7314
```

Les coefficients α0 α1 et β1 sont significatifs pvalue=2e-16 dans le modèle GARCH(1,1). Le test de Box-Ljung sur les carrés des résidus indique que toute l'hétéroscédasticité conditionnelle a été prise en compte.

```
ArchTest(volatrte$res,lag=1)
```

```
Chi-squared = 0.11764, df = 1, p-value = 0.7316
```

```
ArchTest(volatrte$res,lag=20)
```

```
Chi-squared = 9.4563, df = 20, p-value = 0.977
```

Aucun des tests Arch effectués n'est significatif (p>0.05), on en conclut que notre modèle a bien pris en compte toute l'hétéroscédasticité conditionnelle. Notre modèle GARCH(1,1) avec un MA(10) modélise toute l'autocorrélation et hétéroscédasticité.

```
anscombe.test(volatrte$res)
```

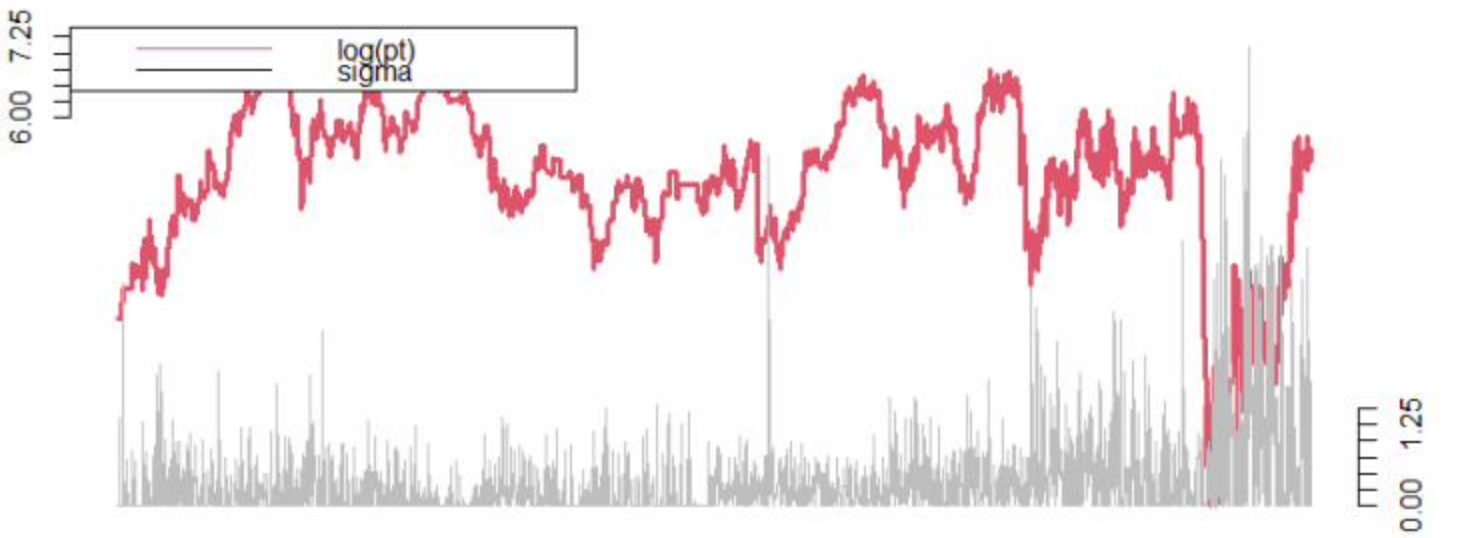
```
data:  volatrte$res
kurt = 13.679, z = 20.505, p-value < 2.2e-16
alternative hypothesis: kurtosis is not equal to 3
```

La p-value < 2.2e-16 du test d'Anscombe-Glynn sur les résidus du modèle GARCH(1,1) permet de rejeter l'hypothèse de normalité et indique clairement la présence de queues épaisses conditionnelles.

Propriété 6 Effet de levier

```
sig<-rep(0,Trte)
for(t in 1:Trte){
 sig[t]<-sqrt(sum(rte[t-22]-(sum(rte[t-22]/22)))^2/22)}
sigma=sig[24:Trte]*100
plot(log(pt[24:Trte]),type='l',col=2,axes=F,xlab="", ylab="",lwd=3)
axis(2,at=seq(6,8.5,by=0.25))#axe de gauche
par(new=Trte)
```

```
plot(sigma, col="grey",type='l',axes = F,xlab="", ylab="")
axis(4,at=seq(0,1.5,by=0.25))#axe de droite
legend("topleft", c("log(pt)","sigma"),col = c(2, 1),lty=c(1,1))
```



Le log du prix met en évidence les phases de hausse, les corrections et les épisodes plus plats, tandis que la courbe sigma traduit les variations de volatilité du marché : on note des pics de sigma qui correspondent à des périodes de forte incertitude ou d'événements extrêmes. La plus grande baisse observée sur la période, le 10 juin 2020, correspond à un rendement de -0.284 et s'accompagne d'une volatilité locale exceptionnellement élevée (0.76), code en (annexe).

Propriété 7 : La saisonnalité

On teste la présence d'un effet de jour de la semaine ('effet week-end') sur les rendements. L'hypothèse nulle (H_0) postule l'absence d'effet spécifique : les caractéristiques des rendements sont similaires quel que soit le jour. On rejette H_0 si l'analyse des moyennes, volatilités ou moments d'ordre supérieur montre des différences nettes entre les jours de la semaine,

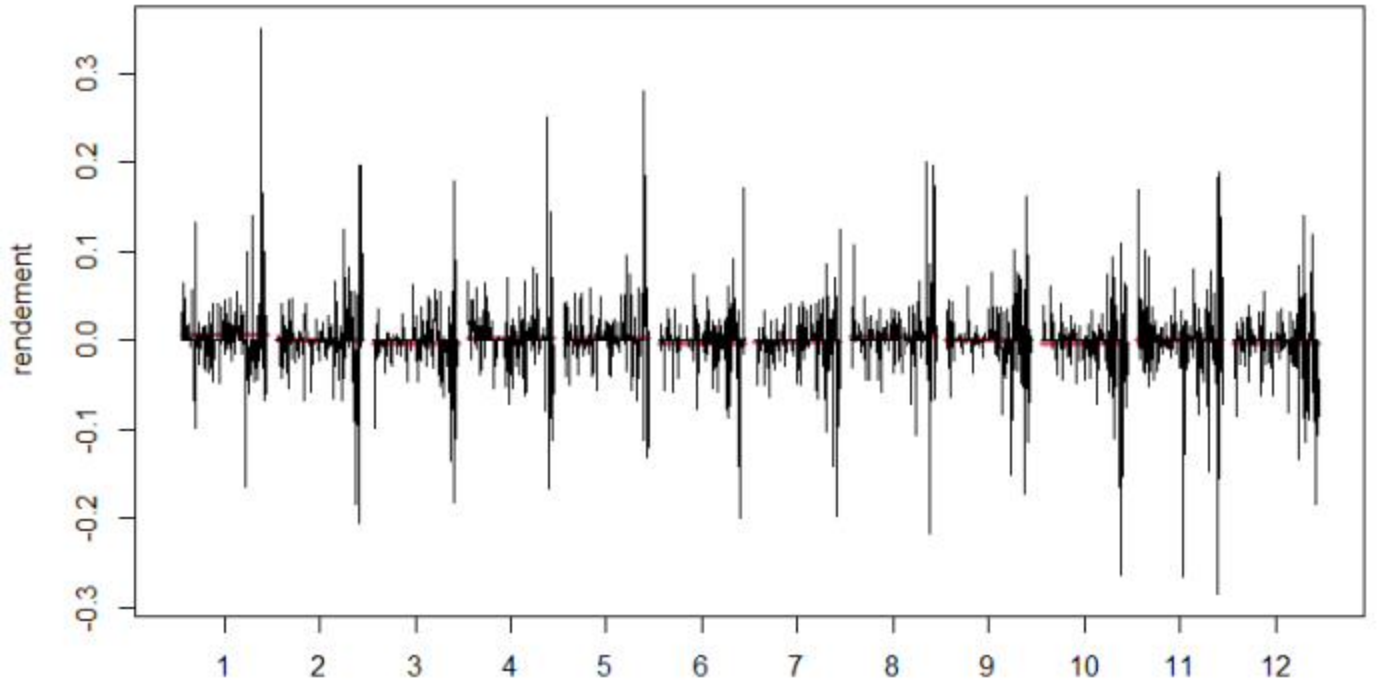
```
jour=format(dates[1:Trte], format = "%A")
tableaures <- data.frame(matrix(NA,ncol=5,nrow=4))
colnames(tableaures) <- c("lundi","mardi","mercredi","jeudi","vendredi")
rownames(tableaures) <- c("moyenne en %","?cart-type annuel en %","skewness","kurtosis")
rtmar<-as.numeric(rte[jour=="mardi"])
mardi<-mean(rtmar) #moyenne journaliere
tableaures[1,2] <- mardi*100 #moyenne journaliere en %
tableaures[2,2] <- sd(rtmar)*100*sqrt(252) #ecart-type annualise en %
tableaures[3,2] <- skewness(rtmar)
tableaures[4,2] <- kurtosis(rtmar)
rtmer<-as.numeric(rte[jour=="mercredi"])
mer<-mean(rtmer)
tableaures[1,3] <- mer*100
tableaures[2,3] <- sd(rtmer)*100*sqrt(252)
tableaures[3,3] <- skewness(rtmer)
tableaures[4,3] <- kurtosis(rtmer)
rtjeu<-as.numeric(rte[jour=="jeudi"])
jeudi<-mean(rtjeu)
tableaures[1,4] <- jeudi*100
tableaures[2,4] <- sd(rtjeu)*100*sqrt(252)
tableaures[3,4] <- skewness(rtjeu)
tableaures[4,4] <- kurtosis(rtjeu)
rtven<-as.numeric(rte[jour=="vendredi"])
```

```
ven<-mean(rtven)
tableaures[1,5] <- ven*100
tableaures[2,5] <- sd(rtven)*100*sqrt(252)
tableaures[3,5] <- skewness(rtven)
tableaures[4,5] <- kurtosis(rtven)
rtlun<-as.numeric(rte[jour=="lundi"])
lundi<-mean(rtlun)
tableaures[1,1] <- lundi*100
tableaures[2,1] <- sd(rtlun)*100*sqrt(252)
tableaures[3,1] <- skewness(rtlun)
tableaures[4,1] <- kurtosis(rtlun)
```

	lundi	mardi	mercredi	jeudi	vendredi
moyenne en %	0.1553965	0.09912528	0.03387457	-0.3278614	0.1982070
?cart-type annuel en %	61.4948325	51.32300506	55.61090298	67.7532792	55.9254378
skewness	2.1033828	0.11181878	0.17748271	-1.2522617	0.2296732
kurtosis	20.8160095	12.47135238	18.74996032	15.2307825	9.6931429

Les rendements moyens sont positifs pour tous les jours sauf le jeudi, il présente une moyenne particulièrement négative (−0.33 %), ce qui suggère un "effet jeudi" défavorable. De plus la volatilité est plus élevée le jeudi (67.75 %). Le lundi se distingue par une forte asymétrie positive (2.10), indiquant plus de grands rendements positifs. À l'inverse, le jeudi montre une asymétrie négative (−1.25). Ces différences nettes entre les jours permettent de rejeter l'hypothèse nulle d'absence de saisonnalité hebdomadaire, il existe bien un effet de jour.

```
monthplot(rte, ylab="rendement",main="", cex.main=1,col.base=2,lwd.base=3)
```



Le mois le plus haut en moyenne de rendement semble être janvier on observe plus de pics positifs
Le mois le plus bas en moyenne correspond à la période autour du mois 3 ou 6, où les rendements négatifs sont les plus fréquents et profonds. La volatilité la plus grande est observée lors des pics marqués autour des mois 1 et 11 où les variations journalières sont bien plus amples. Ces effets saisonniers sont essentiels à prendre en compte pour la gestion du risque et la stratégie d'investissement

Annexe :

```
summary(ur.df ( rte, type="trend", lags=0))
```

```
Test regression trend
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt)
Residuals:
     Min       1Q   Median       3Q      Max
-0.30750 -0.00617 -0.00053  0.00688  0.34959
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.211e-03  1.536e-03   0.788    0.431
z.lag.1     -1.156e+00  2.078e-02 -55.648   <2e-16 ***
tt          -7.611e-07  1.175e-06  -0.648    0.517
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.03652 on 2260 degrees of freedom
Multiple R-squared:  0.5781,   Adjusted R-squared:  0.5777
F-statistic:  1548 on 2 and 2260 DF,  p-value: < 2.2e-16
Value of test-statistic is: -55.6484 1032.25 1548.374
Critical values for test statistics:
      1pct  5pct 10pct
tau3 -3.96 -3.41 -3.12
phi2  6.09  4.68  4.03
phi3  8.27  6.25  5.34
```

Comme on a β1 n’est pas significatif car la pvalue est supérieur à 5% (0.517 > 5%) alors la spécification ”trend ”n’est p as la bonne et nous passons à la spécification ”drift”

```
summary(ur.df (rte, type="drift", lags=0))
```

```
Test regression drift
Call:
lm(formula = z.diff ~ z.lag.1 + 1)
Residuals:
     Min       1Q   Median       3Q      Max
-0.30823 -0.00622 -0.00035  0.00698  0.34884
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.0003489  0.0007676   0.455    0.649
z.lag.1     -1.1560921  0.0207737 -55.652   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
Residual standard error: 0.03652 on 2261 degrees of freedom
Multiple R-squared:  0.578,    Adjusted R-squared:  0.5778
F-statistic:  3097 on 1 and 2261 DF,  p-value: < 2.2e-16
Value of test-statistic is: -55.6518 1548.562
Critical values for test statistics:
      1pct  5pct 10pct
tau2 -3.43 -2.86 -2.57
phi1  6.43  4.59  3.78
```

On regarde si β0 n’est pas significatif ici c’est le cas (0.649 > 5%), nous allons estimer la régression « none ».

```
Schwert<- as.integer(12*(Trte/100)**(0.25))
summary(CADFtest(rte, criterion="MAIC", type="none", max.lag.y=Schwert))
```

```
Augmented DF test

                                      ADF test
t-test statistic:                    -55.43846
```

```
p-value:                                        0.00010
Max lag of the diff. dependent variable:        0.00000

Call:
dynlm(formula = formula(model), start = obs.1, end = obs.T)
Residuals:
     Min       1Q   Median       3Q      Max
-0.30814 -0.00602  0.00000  0.00737  0.34918

Coefficients:
        Estimate Std. Error t value Pr(>|t|)
L(y, 1) -1.15777    0.02088  -55.44    1e-04 ***
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
Residual standard error: 0.03651 on 2236 degrees of freedom
Multiple R-squared:  0.5789,   Adjusted R-squared:  0.5787
F-statistic:    NA on NA and NA DF,  p-value: NA
```

Le test de Dickey-Fuller augmenté avec le critère MAIC nous donne max.lag = 0. On refait alors le test avec lag = schwert.

```
regrte<-Arima(rte, order=c(0,0,10))
coeftest(regrte)
regrte<-Arima(rte, order=c(0,0,10),fixed=c(NA,NA,NA,NA,0,0,0,NA,0,NA,0))
coeftest(regrte)
```

```
z test of coefficients:
             Estimate  Std. Error  z value  Pr(>|z|)
ma1       -0.34352339  0.02867852 -11.9784 < 2.2e-16 ***
ma2       -0.11580434  0.03037956  -3.8119 0.0001379 ***
ma3       -0.04706083  0.03055977  -1.5400 0.1235700
ma4        0.06003307  0.03050457   1.9680 0.0490678 *
ma5       -0.04085211  0.03034976  -1.3460 0.1782883
ma6       -0.02457798  0.03015690  -0.8150 0.4150702
ma7        0.01694634  0.03119503   0.5432 0.5869656
ma8       -0.00164300  0.03159983  -0.0520 0.9585334
ma9       -0.01270352  0.03092942  -0.4107 0.6812733
ma10      -0.02359430  0.02805068  -0.8411 0.4002745
intercept  0.00075278  0.00049437   1.5227 0.1278358
Signif. codes:
0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
> regrtt<-Arima(rtt, order=c(0,0,10),fixed=c(NA,NA,NA,NA,0,0,0,NA,0,NA,0))
> coeftest(regrtt)
z test of coefficients:
       Estimate Std. Error  z value  Pr(>|z|)
ma1  -0.3393316  0.0286975 -11.8244 < 2.2e-16 ***
ma2  -0.1162363  0.0298637  -3.8922 9.933e-05 ***
ma3  -0.0520887  0.0307983  -1.6913   0.09078 .
ma4   0.0463467  0.0291502   1.5899   0.11185
ma8  -0.0054157  0.0284927  -0.1901   0.84925
ma10 -0.0214266  0.0260702  -0.8219   0.41114
---
Signif. codes:
0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Pour le premier test on a des coefficients qui sont significatifs et non significatif or on ne veut que des coefficients avec des pvalues inférieur à 5% on va donc enlever celles qui dépassent ce seuil. Et recommencer une deuxième fois vu que c'était nécessaire et on arrivera à garder que nos bonnes variables.

```
sig<-rep(0,Trte)
```

```
for(t in 1:Trte)
{
 sig[t]<-sqrt(sum(rte[t-22]-(sum(rte[t-22]/22)))^2/22)
}
sigma=sig[24:Trte]*100


plot(log(pt[24:Trte]),type='l',col=2,axes=F,xlab="", ylab="",lwd=3)
par(new=Trte)
plot(sigma, col="grey",type='l',axes = F,xlab="", ylab="")
axis(4,at=seq(0,1.5,by=0.25))#axe de droite
axis(2,at=seq(6,8.5,by=0.25))#axe de gauche
legend("topleft", c("log(pt)","sigma"),col = c(2, 1),lty=c(1,1))
window <- 22
# On suppose que 'datesp' est le vecteur des dates original (tous points), et 'sigma' déjà calculé sur la même base
logpt <- log(pt[window:Trte])
rendements <- rt[window:Trte]
dates_ <- datesp[window:Trte]

# Trouver la plus grande baisse (= minimum du rendement)
ix_min <- which.min(rendements)   # indice de la plus forte baisse
date_min <- dates_[ix_min]      # date correspondante
baisse_min <- rendements[ix_min]  # valeur de la baisse (négatif)

# Volatilité sigma associée à cette date
vol_min <- sigma[ix_min]       # attention : sigma commence à window, donc bon alignement

cat("La plus grande baisse est le", as.character(date_min),
  "avec une valeur de", baisse_min,
  "et une volatilité sigma associée de", vol_min, "\n")
La plus grande baisse est le 2020-06-10 avec une valeur de -0.2839437 et une volatilité sigma associée de 0.7602279


summary(ur.df(rtt,type="trend",lags=0))
Test regression trend
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt)
Residuals:
      Min        1Q    Median        3Q       Max
-0.170467 -0.019839 -0.000153  0.020561  0.213544
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  9.959e-04  2.175e-03   0.458    0.647
z.lag.1     -1.265e+00  2.766e-02 -45.739   <2e-16 ***
tt          -8.460e-08  3.092e-06  -0.027    0.978
Signif. codes:
0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
Residual standard error: 0.03794 on 1215 degrees of freedom
Multiple R-squared:  0.6326,   Adjusted R-squared:  0.632
F-statistic:  1046 on 2 and 1215 DF,  p-value: < 2.2e-16
Value of test-statistic is: -45.7392 697.3585 1046.037
Critical values for test statistics:
```

```
      1pct  5pct 10pct
tau3 -3.96 -3.41 -3.12
phi2  6.09  4.68  4.03
phi3  8.27  6.25  5.34
```

Comme on a β1 n'est pas significatif car la pvalue est supérieur à 5% (0.978 > 5%) alors la spécification "trend "n'est p as la bonne et nous passons à la spécification "drift"

```
summary(ur.df(rtt,type="drift",lags=0))
```

```
Test regression drift
Call:
lm(formula = z.diff ~ z.lag.1 + 1)
Residuals:
      Min        1Q    Median        3Q       Max
-0.170427 -0.019825 -0.000174  0.020585  0.213581
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.0009443  0.0010868   0.869    0.385
z.lag.1     -1.2650658  0.0276469 -45.758   <2e-16 ***
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.03792 on 1216 degrees of freedom
Multiple R-squared:  0.6326,   Adjusted R-squared:  0.6323
F-statistic:  2094 on 1 and 1216 DF,  p-value: < 2.2e-16
Value of test-statistic is: -45.758 1046.898
Critical values for test statistics:
      1pct  5pct 10pct
tau2 -3.43 -2.86 -2.57
phi1  6.43  4.59  3.78
```

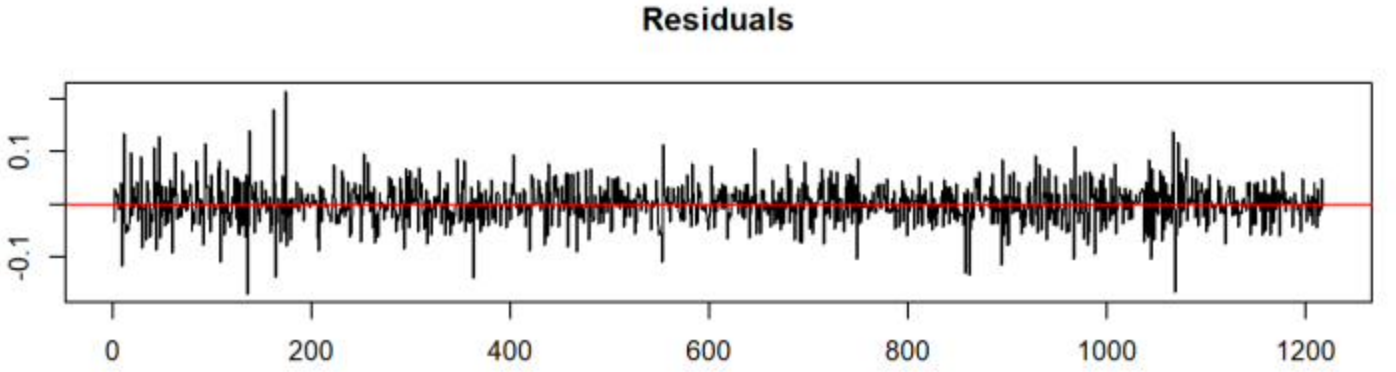
On regarde si β0 n'est pas significatif ici c'est le cas (0.385 > 5%), nous allons estimer la régression « none ».

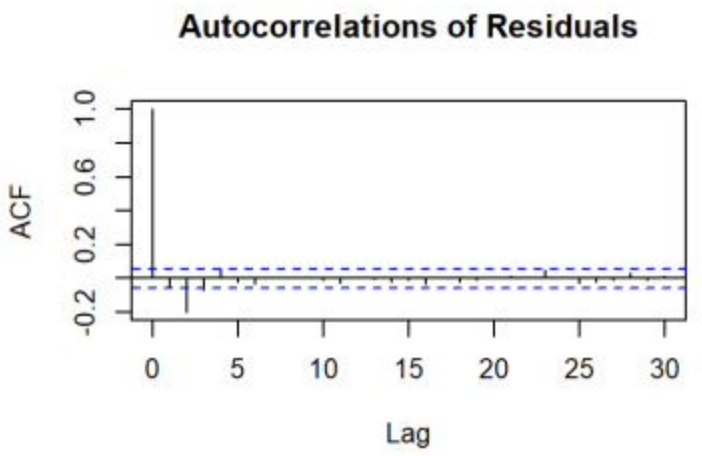
```
summary(ur.df(rtt,type="none",lags=0))
```

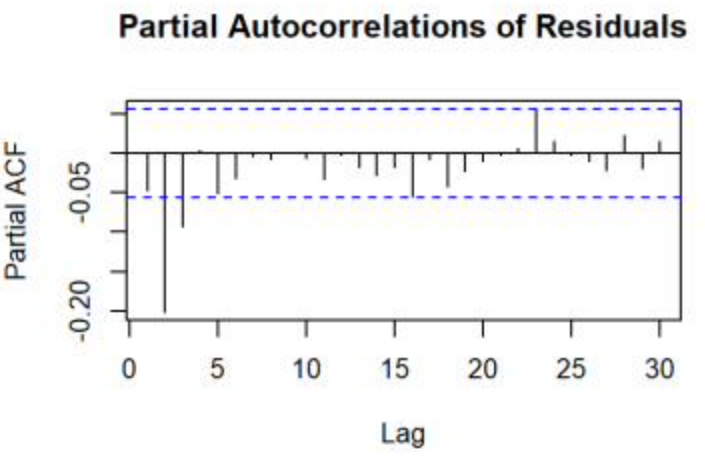
```
Test regression none
Call:
lm(formula = z.diff ~ z.lag.1 - 1)
Residuals:
      Min        1Q    Median        3Q       Max
-0.169519 -0.018867  0.000772  0.021528  0.214526
Coefficients:
        Estimate Std. Error t value Pr(>|t|)
z.lag.1 -1.26459    0.02764  -45.75   <2e-16 ***
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.03792 on 1217 degrees of freedom
Multiple R-squared:  0.6324, Adjusted R-squared:  0.6321
F-statistic:  2093 on 1 and 1217 DF,  p-value: < 2.2e-16
Value of test-statistic is: -45.7544
Critical values for test statistics:
      1pct  5pct 10pct
tau1 -2.58 -1.95 -1.62
```

t calculé =−45.75 <-1.95 donc on rejette H0 donc le PGD n'est pas DS. On rejette donc l'hypothèse de racine unitaire : la série des rendements rtt de Banorte est stationnaire. Cette conclusion n'est valide que si les aléas de la régression de Dickey et Fuller ne sont pas auto-corrélés.

```
plot(ur.df(rtt,type = "none", lags = 0))
```







On constate la présence d'autocorrélations dans les résidus surtout dans les premiers lags, on augmente alors le nombre maximum de lag du modèle Dickey-Fuller augmenté.

```
Schwert<- as.integer(12*(Trtt/100)**(0.25))
summary(CADFtest(rtt, criterion="MAIC", type="none", max.lag.y=Schwert))
```

```
Augmented DF test
                                          ADF test
t-test statistic:                         -45.2636
p-value:                                    0.0001
Max lag of the diff. dependent variable:    0.0000
Call:
dynlm(formula = formula(model), start = obs.1, end = obs.T)
Residuals:
      Min        1Q    Median        3Q       Max
-0.169618 -0.018684  0.001094  0.021446  0.214526
Coefficients:
       Estimate Std. Error t value Pr(>|t|)
L(y, 1) -1.26329    0.02791  -45.26    1e-04 ***
---
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.03762 on 1195 degrees of freedom
Multiple R-squared:  0.6316,   Adjusted R-squared:  0.6313
F-statistic:    NA on NA and NA DF,  p-value: NA
```

Le test de Dickey-Fuller augmenté avec le critère MAIC nous donne max.lag = 0 . On refait alors le test avec lag = schwert.

```
summary(ur.df(rtt,type= "none",lags=Schwert))
```

```
Test regression none
Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
Residuals:
     Min       1Q   Median       3Q      Max
-0.17446 -0.01898  0.00214  0.02283  0.19488
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
z.lag.1      -2.189930   0.267105  -8.199 6.31e-16 ***
z.diff.lag1   0.850889   0.261272   3.257  0.00116 **
z.diff.lag2   0.621586   0.254041   2.447  0.01456 *
z.diff.lag3   0.454277   0.245923   1.847  0.06497 .
z.diff.lag4   0.421982   0.237252   1.779  0.07556 .
z.diff.lag5   0.368561   0.228422   1.614  0.10690
z.diff.lag6   0.320013   0.219502   1.458  0.14514
z.diff.lag7   0.303631   0.210408   1.443  0.14927
z.diff.lag8   0.291443   0.201545   1.446  0.14843
z.diff.lag9   0.282643   0.192611   1.467  0.14253
z.diff.lag10  0.271210   0.183696   1.476  0.14010
z.diff.lag11  0.232960   0.174624   1.334  0.18244
z.diff.lag12  0.215263   0.165227   1.303  0.19289
z.diff.lag13  0.185570   0.155704   1.192  0.23358
z.diff.lag14  0.138139   0.145644   0.948  0.34308
z.diff.lag15  0.102077   0.134932   0.757  0.44950
z.diff.lag16  0.030332   0.123410   0.246  0.80589
z.diff.lag17  0.003739   0.110837   0.034  0.97310
z.diff.lag18 -0.040183   0.097444  -0.412  0.68014
z.diff.lag19 -0.070245   0.082946  -0.847  0.39724
z.diff.lag20 -0.075644   0.066126  -1.144  0.25288
z.diff.lag21 -0.065516   0.048155  -1.361  0.17392
z.diff.lag22 -0.052493   0.028789  -1.823  0.06850 .
---
Signif. codes:
0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
Residual standard error: 0.03678 on 1173 degrees of freedom
Multiple R-squared:  0.6544,   Adjusted R-squared:  0.6477
F-statistic: 96.58 on 23 and 1173 DF,  p-value: < 2.2e-16
Value of test-statistic is: -8.1988
Critical values for test statistics:
      1pct  5pct 10pct
tau1 -2.58 -1.95 -1.62
```

Schwert (22) correspond au nombre de lag qui rend le dernier lag significatif (| t |> 1.6). En utilisant le test Augmented Dickey-Fuller, on obtient une statistique de test de -8.198, nettement plus négative que la valeur critique de -1.95 au seuil de 5 %. On rejette donc avec certitude l'hypothèse de non-stationnarité : la série rtt de Banorte est stationnaire sur la période considérée.

```
summary(ur.za(rtt, model="both", lag=Schwert))
```

```
Call:
lm(formula = testmat)
Residuals:
     Min       1Q   Median       3Q      Max
-0.17851 -0.02012  0.00019  0.02178  0.19041
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.024e-03  2.374e-03   1.695 0.090370 .
y.l1        -1.490e+00  2.803e-01  -5.315 1.28e-07 ***
trend       -4.902e-06  3.764e-06  -1.303 0.192983
y.dl1        1.141e+00  2.739e-01   4.165 3.34e-05 ***
```

```
y.dl2         8.989e-01  2.659e-01   3.380 0.000748 ***
y.dl3         7.186e-01  2.570e-01   2.796 0.005262 **
y.dl4         6.726e-01  2.476e-01   2.717 0.006694 **
y.dl5         6.042e-01  2.379e-01   2.540 0.011225 *
y.dl6         5.397e-01  2.281e-01   2.367 0.018114 *
y.dl7         5.075e-01  2.181e-01   2.327 0.020122 *
y.dl8         4.804e-01  2.084e-01   2.305 0.021326 *
y.dl9         4.571e-01  1.987e-01   2.301 0.021588 *
y.dl10        4.317e-01  1.891e-01   2.283 0.022584 *
y.dl11        3.804e-01  1.794e-01   2.121 0.034163 *
y.dl12        3.491e-01  1.693e-01   2.062 0.039464 *
y.dl13        3.063e-01  1.592e-01   1.924 0.054613 .
y.dl14        2.469e-01  1.487e-01   1.661 0.097015 .
y.dl15        1.982e-01  1.374e-01   1.442 0.149570
y.dl16        1.143e-01  1.255e-01   0.911 0.362427
y.dl17        7.503e-02  1.124e-01   0.667 0.504711
y.dl18        1.801e-02  9.862e-02   0.183 0.855103
y.dl19       -2.546e-02  8.371e-02  -0.304 0.761064
y.dl20       -4.437e-02  6.654e-02  -0.667 0.505051
y.dl21       -4.657e-02  4.831e-02  -0.964 0.335291
y.dl22       -4.422e-02  2.879e-02  -1.536 0.124854
du            2.012e-02  6.695e-03   3.006 0.002705 **
dt           -1.631e-04  7.246e-05  -2.252 0.024532 *
---
Signif. codes:
0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
Residual standard error: 0.03665 on 1169 degrees of freedom
  (23 observations effacées parce que manquantes)
Multiple R-squared:  0.1355,   Adjusted R-squared:  0.1162
F-statistic: 7.045 on 26 and 1169 DF,  p-value: < 2.2e-16
Teststatistic: -8.8826
Critical values: 0.01= -5.57 0.05= -5.08 0.1= -4.82
Potential break point at position: 1072
```

Le test Zivot-Andrews pour la stationnarité des rendements logarithmiques de Banorte, avec optimisation du lag par Schwert, révèle une statistique de test de –8.8826, nettement inférieure à la valeur critique de –5.08 au seuil de 5 %. Les coefficients de rupture sont tous deux significatifs. On rejette donc H0 et conclut que la série est stationnaire, même en tenant compte d'une rupture structurelle significative autour de la position 1072."

```
myBreaks <- 1
myModel <- "break"
myLags <- 5
myLS_test <- ur.ls(y=rtt , model = myModel, breaks = myBreaks, lags = myLags, method
= "GTOS",pn = 0.1, print.results = "print" )
-27.79732
[1] "First possible structural break at position: 801"
[1] "The location of the first break - lambda_1: 0.7 , with the number of total obse
rvations: 1219"
Critical values - Break model:
     lambda    1%    5%   10%
[1,]    0.1 -5.11 -4.50 -4.21
[2,]    0.2 -5.07 -4.47 -4.20
[3,]    0.3 -5.15 -4.45 -4.18
[4,]    0.4 -5.05 -4.50 -4.18
[5,]    0.5 -5.11 -4.51 -4.17
[1] "Number of lags determined by general-to-specific lag selection: 2"
Runtime:
```

```
Time difference of 0.04958065 mins
```

Le test Lee-Strazicich donne une statistique de test de –27.79732, nettement plus faible que la valeur critique de –4.51 au seuil de 5 %. On rejette donc l'hypothèse de racine unitaire, ce qui valide la stationnarité de rtt, même lorsque l'on considère l'existence d'une rupture structurelle à la position 801, c'est-à-dire vers les ¾ de la période d'analyse.

```
agostino.test(rtt)
```

```
        D'Agostino skewness test

data:  rtt
skew = 0.097088, z = 1.389050, p-value = 0.1648
alternative hypothesis: data have a skewness
```

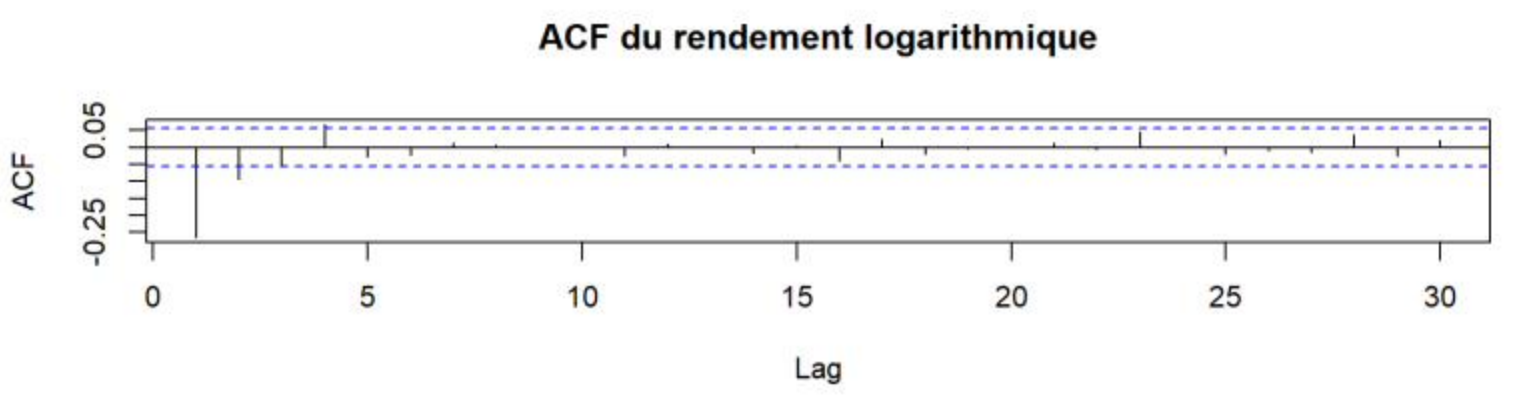
Ici, la p-value 0.1648 est supérieure à 0.05, donc on ne rejette pas l'hypothèse nulle d'absence d'asymétrie.
La distribution des rendements rtt est donc considérée comme globalement symétrique, sans tendance marquée pour les valeurs extrêmes à gauche ou à droite.

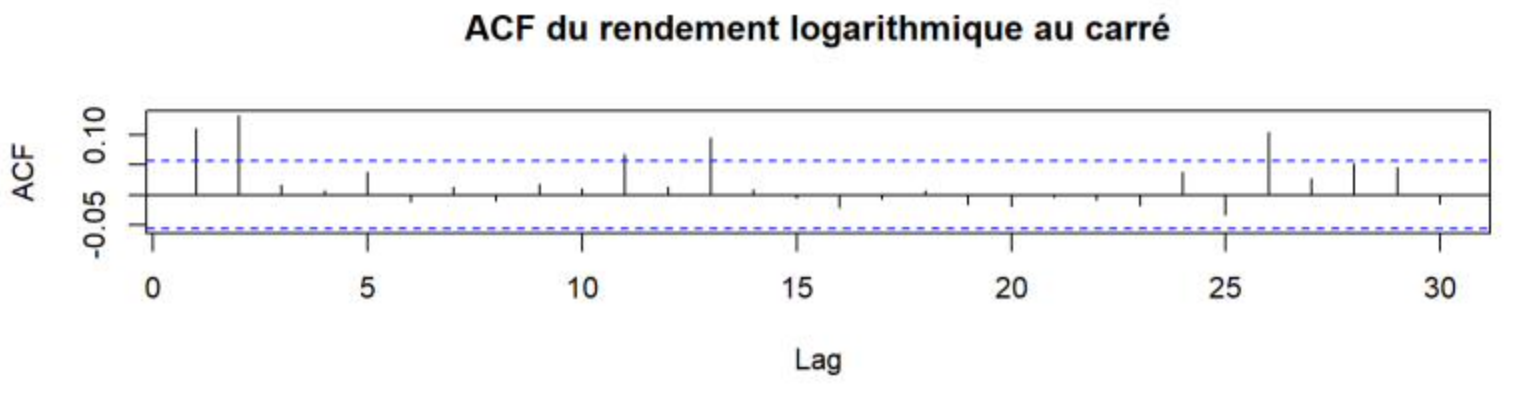
```
anscombe.test(rtt)
```

```
Anscombe-Glynn kurtosis test
data:  rtt
kurt = 5.5346, z = 8.7776, p-value < 2.2e-16
alternative hypothesis: kurtosis is not equal to 3
```

Ici, la p-value est extrêmement faible <2.2e-16, donc on rejette sans ambiguïté l'hypothèse de kurtosis normale.
La série des rendements rtt présente une leptokurticité significative : la distribution a des queues plus épaisses que la normale, indiquant une fréquence accrue de valeurs extrêmes.

```
op<-par(mfrow=c(2,1))
Acf(rtt,main='ACF du rendement logarithmique')
Acf(rtt^2,main='ACF du rendement logarithmique au carré')
par(op
```





Pour le rendement logarithmique de rtt, les coefficients d'autocorrélation restent très proches de zéro à tous les lags, avec quasiment toutes les barres à l'intérieur de l'intervalle de confiance sauf pour lag 1,2 et 4
Pour le carré des rendements, plusieurs coefficients d'autocorrélation sont supérieurs à zéro et dépassent l'intervalle de confiance, lags 1, 2, 11, 13 et 26 : cela indique une dépendance significative dans la volatilité. Autrement dit, une période de haute volatilité tend à être suivie d'autres périodes de forte volatilité. Ce phénomène est typique de la plupart des séries financières et justifie l'utilisation de modèles ARCH/GARCH pour expliquer la dynamique de la variance

```
 pvaluesrtt =rep(0,20)
 pvaluesrtt2 =rep(0,20)
 for (i in 1:25 ) {
  pvaluesrtt[i] = Box.test(rtt,lag=i,type="Ljung-Box")$p.value
  pvaluesrtt2[i] = Box.test(rtt^2,lag=i,type="Ljung-Box")$p.value
 }
 pvaluesrtt
 pvaluesrtt2
```

```
pvaluesrtt
[1]  0.000000e+00 0.000000e+00 0.000000e+00
 [4] 0.000000e+00 0.000000e+00 0.000000e+00
 [7] 0.000000e+00 0.000000e+00 0.000000e+00
[10] 0.000000e+00 0.000000e+00 0.000000e+00
[13] 0.000000e+00 1.110223e-16 2.220446e-16
[16] 3.330669e-16 6.661338e-16 1.443290e-15
[19] 3.552714e-15 8.770762e-15 1.953993e-14
[22] 4.563017e-14 3.674838e-14 8.382184e-14
[25] 1.565414e-13
>   pvaluesrtt2
 [1] 9.656505e-05 9.956014e-09 4.258568e-08
 [4] 1.617352e-07 2.403669e-07 6.686219e-07
 [7] 1.671615e-06 4.019959e-06 7.970515e-06
[10] 1.687362e-05 3.796731e-06 7.434932e-06
[13] 1.682730e-07 3.523795e-07 7.330984e-07
[16] 1.213646e-06 2.333473e-06 4.368577e-06
[19] 7.156430e-06 1.115854e-05 1.964359e-05
[22] 3.311937e-05 4.970679e-05 4.489203e-05
[25] 4.775200e-05
```

Cela signifie qu'on rejette systématiquement l'hypothèse d'absence d'autocorrélation : il existe une autocorrélation fortement significative dans la série des rendements.
Pour rtt^2 (volatilité) : les p-values sont toutes très faibles (bien inférieures à 0.05) pour chaque lag testé.
On rejette aussi l'absence d'autocorrélation dans la volatilité : la volatilité présente une forte dépendance temporelle, conforme au phénomène de clustering de volatilité observée dans la plupart des marchés financiers.

```
 eacf(rtt)
```

```
AR/MA
  0 1 2 3 4 5 6 7 8 9 10 11 12 13
0 x x o x o o o o o o o  o  o  o
1 x o x o o o o o o o o  o  o  o
2 x x x o o o o o o o o  o  o  o
3 x x x x o o o o o o o  o  o  o
4 x x x o x o o o o o o  o  o  o
5 x x x x x o o o o o o  o  o  o
6 x x o x o o o o o o o  o  o  o
7 x o o o x o x x o o o  o  o  o
```

On trouve que p = 0 et q = 4. On fait donc l'estimation d'un MA(4)

```
regrtt<-Arima(rtt, order=c(0,0,4))
coeftest(regrtt)
```

```
z test of coefficients:
             Estimate  Std. Error  z value  Pr(>|z|)
ma1       -0.33851691  0.02863954 -11.8199 < 2.2e-16 ***
ma2       -0.11640298  0.02982854  -3.9024 9.524e-05 ***
ma3       -0.05118229  0.03065397  -1.6697   0.09498 .
ma4        0.04720915  0.02942246   1.6045   0.10860
intercept  0.00075398  0.00057272   1.3165   0.18801
---
Signif. codes:
0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Les pvalues de ma1 ($< 2.2e-16$) et ma2 (9.524^{e}-05) (p-value << 0.05) : ces coefficients de moyenne mobile traduisent de véritables dépendances dans les rendements, et doivent être conservés dans le modèle.
Pour les pvlaues de ma3, ma4 et Intercept elles sont tous supérieur à va devoir refaire un Arima en les enlevant du modèle pour avoir un meilleur modèle.

```
regrtt<-Arima(rtt, order=c(0,0,4),fixed=c(NA,NA,0,0,0))
coeftest(regrtt)
```

```
z test of coefficients:

    Estimate Std. Error  z value  Pr(>|z|)
ma1 -0.34606    0.02802 -12.3505 < 2.2e-16 ***
ma2 -0.11817    0.02747  -4.3018 1.694e-05 ***
---
Signif. codes:
0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

Les pvalues de ma1 ($< 2.2e-16$) et ma2 ($1.694e-05$) sont toutes les deux < 0.05.
Ces coefficients montrent une dépendance marquée de la série rtt aux deux premiers retards, ce qui reflète une autocorrélation de court terme substantielle dans les rendements.
En forçant les autres coefficients à zéro, on obtient un modèle parcimonieux, statistiquement solide et plus stable, qui ne conserve que les dépendances réellement pertinentes. Les coefficients non significatifs sont supprimés pour éviter la sur-spécification et clarifier la dynamique réelle de la série et avoir un meilleur modèle

```
residurtt<-regrtt$res
t.test(residurtt)
```

```
One Sample t-test
data:  residurtt
t = 1.3349, df = 1218, p-value = 0.1822
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.0006635909  0.0034892881
sample estimates:
  mean of x
0.001412849
```

Le test t appliqué aux résidus du modèle ARMA permet de vérifier si la moyenne des résidus est bien nulle, comme attendu pour un modèle bien spécifié.La p-value est 0.1822 (donc > 0.05). On ne rejette pas l'hypothèse nulle que la moyenne des résidus est nulle.Cela signifie que le modèle ARMA retenu ajuste correctement la structure moyenne de la série rtt : les résidus ne présentent pas de biais systématique.

```
residuvrtt=(residurtt-mean(residurtt))/sd(residurtt)
K<-20
tmp<-rep(0,K)
for(i in 1:K){
 tmp[i]<-Box.test(residuvrtt,lag=i,type="Ljung-Box")$p.value
}
Tmp
```

```
[1] 0.9440378 0.9828634 0.5516884 0.3034599 0.3406692
 [6] 0.3831046 0.4960368 0.6036654 0.6919713 0.7542010
[11] 0.6947976 0.7611583 0.7904890 0.7411553 0.7655568
[16] 0.6041017 0.6722094 0.6742611 0.7307813 0.7814101
```

Aucune p-value n'est inférieure à 5% jusqu'à l'ordre 20, on en conclut à l'absence d'autocorrélation dans les résidus du modèle et donc à la bonne spécification de ce dernier.

```
ArchTest(as.numeric(rtt),lag=1)
```

```
ARCH LM-test; Null hypothesis: no ARCH effects
data:  as.numeric(rtt)
Chi-squared = 15.155, df = 1, p-value = 9.903e-05
```

On a une p-value de $9.903e-05$ ceci permet de rejeter sans ambiguïté l'hypothèse d'absence d'hétéroscédasticité conditionnelle : la série présente un effet ARCH significatif.

```
volatrtt<-garch(residuvrtt,order=c(1,1))
summary(volatrtt)
```

```
Call:
garch(x = residuvrtt, order = c(1, 1))
Model:
GARCH(1,1)
Residuals:
     Min       1Q   Median       3Q      Max
-4.41027 -0.57955  0.01001  0.56181  5.31773
Coefficient(s):
    Estimate  Std. Error  t value Pr(>|t|)
a0   0.14457     0.03518    4.109 3.97e-05 ***
a1   0.07808     0.01745    4.475 7.64e-06 ***
b1   0.77847     0.04253   18.305  < 2e-16 ***
Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Diagnostic Tests:
        Jarque Bera Test
data:  Residuals
X-squared = 204.21, df = 2, p-value < 2.2e-16
        Box-Ljung test
data:  Squared.Residuals
X-squared = 0.10523, df = 1, p-value = 0.7456
```

Les coefficients α0 α1 et β1 sont significatifs pvalue=2e-16 dans le modèle GARCH(1,1). Le test de Box-Ljung sur les carrés des résidus indique que toute l'hétéroscédasticité conditionnelle a été prise en compte.

```
ArchTest(volatrtt$res,lag=1)
ArchTest(volatrtt$res,lag=20)
```

```
ArchTest(volatrtt$res,lag=1)
```

```
        ARCH LM-test; Null hypothesis: no ARCH effects
data:  volatrtt$res
Chi-squared = 0.10491, df = 1, p-value = 0.746
> ArchTest(volatrtt$res,lag=20)
        ARCH LM-test; Null hypothesis: no ARCH effects
data:  volatrtt$res
Chi-squared = 28.538, df = 20, p-value = 0.09727
```

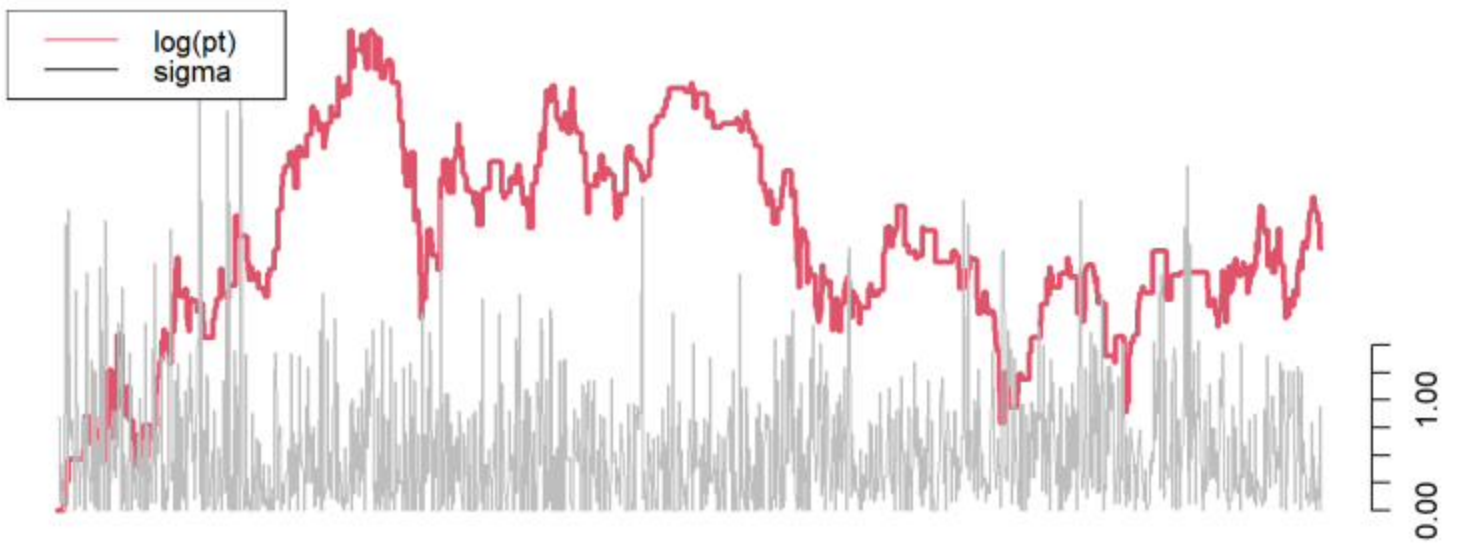
Aucun des tests Arch effectués n'a la pvalue inférieur à 5%, on en conclut que notre modèle a bien pris en compte toute l'hétéroscédasticité conditionnelle.

anscombe.test(volatrtt$res)

```
        Anscombe-Glynn kurtosis test
data:  volatrtt$res
kurt = 5.0051, z = 7.7437, p-value = 9.653e-15
alternative hypothesis: kurtosis is not equal to 3
```

La p-value très faible permet de rejeter nettement H_0, indiquant que les résidus du modèle GARCH ne suivent pas une distribution normale. La kurtosis élevée signifie que la distribution des résidus reste leptokurtique, avec une fréquence supérieure de valeurs extrêmes par rapport à une loi normale, malgré la modélisation de la volatilité conditionnelle par GARCH.

```
sig<-rep(0,Trtt)
for(t in 1:Trtt)
{
 sig[t]<-sqrt(sum(rtt[t-22]-(sum(rtt[t-22]/22)))^2/22)
}
sigma=sig[24:Trtt]*100
plot(log(pt[24:Trtt]),type='l',col=2,axes=F,xlab="", ylab="",lwd=3)
par(new=Trtt)
plot(sigma, col="grey",type='l',axes = F,xlab="", ylab="")
axis(4,at=seq(0,1.5,by=0.25))#axe de droite
axis(2,at=seq(6,8.5,by=0.25))#axe de gauche
legend("topleft", c("log(pt)","sigma"),col = c(2, 1),lty=c(1,1))
```



Le log du prix met en évidence les phases de hausse, les corrections et les épisodes plus plats, tandis que la courbe sigma traduit les variations de volatilité du marché : on note des pics de sigma qui correspondent à des périodes de forte incertitude ou d'événements extrêmes. La plus grande baisse observée sur la période, le 10 juin 2020, correspond à un rendement de -0.284 et s'accompagne d'une volatilité locale exceptionnellement élevée (0.76), code en (annexe).

```
logpt <- log(pt[2265:N])
rendements <- rtt
dates_ <- datesp[2265:N]
ix_min <- which.min(rendements)
date_min <- dates_[ix_min]
baisse_min <- rendements[ix_min]
vol_min <- sigma_[ix_min]
cat("La plus grande baisse est le", as.character(date_min),
  "avec une valeur de", baisse_min,
  "et une volatilité sigma associée de", vol_min, "\n")
```

```
La plus grande baisse est le 2021-07-16 avec une valeur de -0.1896881 et une volatilité sigma associée de 0.1499168
```

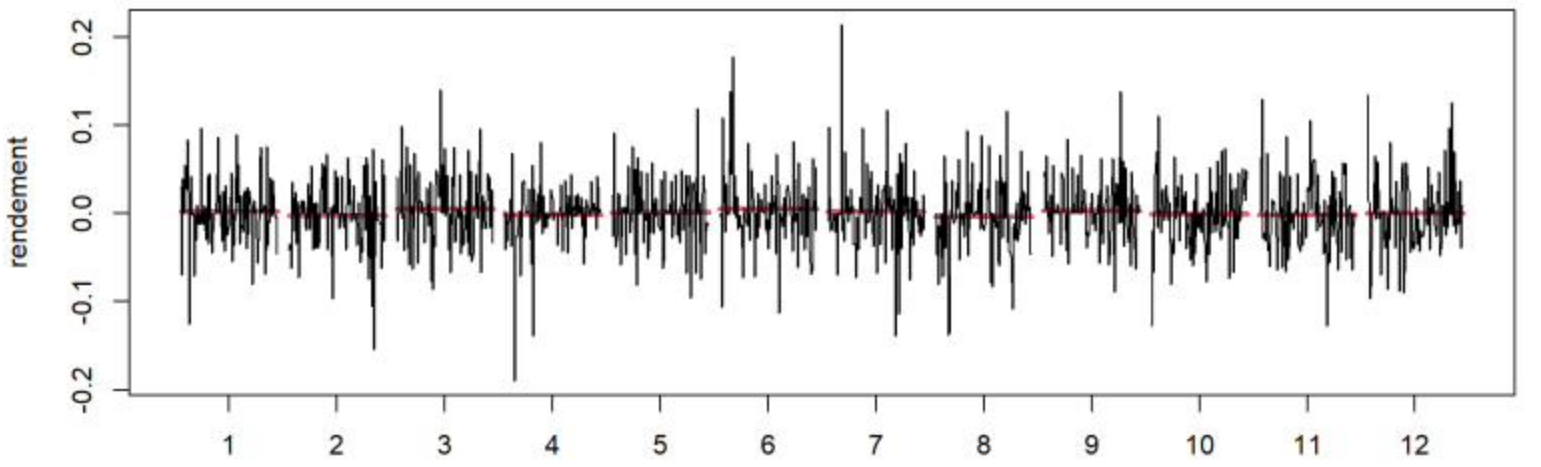
```
jour=format(dates[1:Trtt], format = "%A")
tableaures <- data.frame(matrix(NA,ncol=5,nrow=4))
colnames(tableaures) <- c("lundi","mardi","mercredi","jeudi","vendredi")
rownames(tableaures) <- c("moyenne en %","?cart-type annuel en %","skewness","kurtosis")
rtmar<-as.numeric(rtt[jour=="mardi"])
mardi<-mean(rtmar) #moyenne journaliere
tableaures[1,2] <- mardi*100 #moyenne journaliere en %
tableaures[2,2] <- sd(rtmar)*100*sqrt(252) #ecart-type annualise en %
tableaures[3,2] <- skewness(rtmar)
tableaures[4,2] <- kurtosis(rtmar)
rtmer<-as.numeric(rtt[jour=="mercredi"])
mer<-mean(rtmer)
tableaures[1,3] <- mer*100
tableaures[2,3] <- sd(rtmer)*100*sqrt(252)
tableaures[3,3] <- skewness(rtmer)
tableaures[4,3] <- kurtosis(rtmer)
rtjeu<-as.numeric(rtt[jour=="jeudi"])
jeudi<-mean(rtjeu)
tableaures[1,4] <- jeudi*100
tableaures[2,4] <- sd(rtjeu)*100*sqrt(252)
tableaures[3,4] <- skewness(rtjeu)
tableaures[4,4] <- kurtosis(rtjeu)
rtven<-as.numeric(rtt[jour=="vendredi"])
ven<-mean(rtven)
tableaures[1,5] <- ven*100
tableaures[2,5] <- sd(rtven)*100*sqrt(252)
tableaures[3,5] <- skewness(rtven)
tableaures[4,5] <- kurtosis(rtven)
rtlun<-as.numeric(rtt[jour=="lundi"])
lundi<-mean(rtlun)
tableaures[1,1] <- lundi*100
tableaures[2,1] <- sd(rtlun)*100*sqrt(252)
```

```
tableaures[3,1] <- skewness(rtlun)
tableaures[4,1] <- kurtosis(rtlun)
tableaures
```

	lundi	mardi	mercredi	jeudi	vendredi
moyenne en %	0.07324671	0.53841647	-0.3236727	0.1480896	-0.05521327
?cart-type annuel en %	64.64733622	53.20719696	68.6184118	64.0513817	60.18104807
skewness	0.34036464	0.09662984	-0.2608924	0.3862798	0.17552263
kurtosis	2.03986763	1.30754277	3.7602621	2.2511854	1.26371072

Le mardi affiche la plus forte moyenne positive (0.54 %), suivi du jeudi (0.15 %). Le mercredi présente une moyenne négative (−0.32 %), signalant que c'est le jour le moins favorable. La volatilité est la plus élevée le mercredi (68.6 %), ce qui traduit des mouvements plus brusques ce jour-là, tandis que le mardi connaît la volatilité la plus faible (53.2 %). Aucune journée ne montre une asymétrie très marquée. Le mercredi affiche la valeur la plus élevée (3.76 Kurtosis), indiquant une propension accrue aux valeurs extrêmes, tandis que les autres jours sont plus proches de la normale.

```
monthplot(rtt, ylab="rendement",main="", cex.main=1,col.base=2,lwd.base=3)
```



Le mois de mars semble être le plus haut en moyenne de rendement : on y relève davantage de pics positifs, reflétant une meilleure performance sur cette période. Les mois où les rendements moyens sont les plus bas, avec de nombreux pics négatifs profonds, correspondent principalement à février et août, ce qui indique des risques plus élevés de pertes durant ces périodes.
La volatilité la plus importante se manifeste au milieu de l'année avec juin et juillet, où l'amplitude des variations journalières est nettement plus élevée — ces zones illustrent des épisodes de forte incertitude ou de choc de marché.

Propriété	Série rte(2/3)	Série rtt(1/3)
Stationnarité	Stationnaire ; rejet de la racine unitaire par Dickey-Fuller et Zivot-Andrews, même avec rupture	Stationnaire ; rejet de la racine unitaire à tous les tests
Asymétrie (skewness)	Asymétrie positive modérée et significative (skew > 0, p < 0.05)	Skewness faible et non significative (série globalement symétrique, p > 0.05)
Kurtosis (épaisseur des queues)	Très forte leptokurticité : kurtosis élevée (valeur très supérieure à 3)	Leptokurticité notable mais moins extrême ; kurtosis supérieure à 3 mais nettement plus faible que surrte
Autocorrélation des rendements	Absence/présence faible d'autocorrélation sur les 2 premiers lags ; significative uniquement à partir du lag 3	Autocorrélation forte sur l'ensemble des retards testés (p-values très faibles sur tous les lags)
Clustering de volatilité	Présence marquée, justifiant ARCH/GARCH ; très forte autocorrélation dans les carrés des rendements	Présence également significative, autocorrélation dans rtt^2 forte mais plus variable selon les lags
Modélisation ARMA/GARCH	ARMA(0,10) simplifié (ma1, ma2, ma3, ma4, ma8 significatifs) puis GARCH(1,1) efficace ; résidus du GARCH toujours leptokurtiques	ARMA(0,4) (ma1 et ma2 principaux), GARCH(1,1) performant ; résidus du GARCH moins extrêmes mais toujours leptokurtiques
Effet semaine & saisonnalité	Mouvement moyen négatif le jeudi, volatilité accrue ce jour ; lundi positif avec asymétrie	Mardi le plus haut en moyenne, mercredi défavorable et plus volatil ; pas de forte asymétrie globale
Effet mois	Janvier performant, creux autour de mars/juin ; pics de volatilité en janvier et novembre	Mars performant, creux en mars/juin, volatilité maximum en janvier et novembre, structure moins marquée